

机器学习笔记

Leonhard Hsiao

2025 年 12 月 19 日

目录

1	特征选择和特征降维	1
1.1	特征选择：定义、框架与子集生成算法	1
1.1.1	特征选择的通用框架	1
1.1.2	特征子集生成的搜索策略	2
1.1.3	算法特性对比	3
1.2	特征评价准则：衡量特征子集的优劣	3
1.2.1	基于距离的可分性判据	4
1.2.2	基于概率分布的可分性判据	4
1.2.3	基于熵的判据（信息论视角）	5

1 特征选择和特征降维

在机器学习任务中，原始数据往往拥有极高的维度，进行降维处理主要基于以下四个原因：

- **维度灾难**：随着维度 d 的增加，样本空间体积呈指数级膨胀，导致数据在高维空间变得极其稀疏，模型就很难学到规律，而且有可能把噪声当作数据学习。
- **冗余与噪声**：噪声是指某些特征对于预测任务是无用的，还有可能干扰学习过程；某些特征之间存在高度相似性，比如年龄和出生日期，同时考虑他们两个是没有必要的。
- **计算效率**：减少特征数量可以显著降低模型训练和推理时的计算复杂度，节省内存与存储空间。

虽然两者都旨在降低维度，但在处理手段和结果上有本质区别。特征选择是从原始特征集合中选取一个子集，保持特征的原有意义；特征提取类似于线性映射 $\mathbb{R}^n \rightarrow \mathbb{R}^m$ ，把数据从高维的特征空间映射到低维空间，过程会创造新的特征。

1.1 特征选择：定义、框架与子集生成算法

定义 1.1 (特征选择问题). 特征选择 (Feature Selection) 是指从原始的 D 维特征集合中，挑选出一个包含 d 个特征 ($d < D$) 的子集来表达模式的过程。其核心目标是在尽量减少信息损失的前提下：

- 提高数据的压缩率；
- 提升学习机的预测性能（泛化能力）；
- 加快学习速度并降低计算开销。

1.1.1 特征选择的通用框架

特征选择通常是一个迭代循环的过程，包含四个核心环节：

1. **子集生成**：按照某种搜索策略产生候选的特征子集。
2. **子集评价**：利用评价准则 J 对候选子集进行打分，衡量其优劣。
3. **停止准则**：判断当前搜索是否达到预期目标（如达到指定特征数或评价指标不再提升）。
4. **结果验证**：在独立的测试集上验证最终选定子集的有效性。

1.1.2 特征子集生成的搜索策略

从 D 维特征中选择 d 维特征，其可能的子集个数为组合数：

$$C_D^d = \frac{D!}{(D-d)!d!}$$

当原始维度 D 较大时，搜索空间呈指数级增长。例如，当 $D = 100, d = 10$ 时，组合数约为 1.73×10^{13} 。为了在有限时间内找到理想子集，需要采用不同的搜索策略。

1. 穷举搜索 (Exhaustive Search) 计算特征的所有可能组合并逐一评价。虽然能找到最优子集，但总搜索数 $\sum_{d=1}^D C_D^d = 2^D - 1$ 计算量巨大，仅适用于 D 非常小的情况。

2. 单独最优特征组合 对每个特征 x_i 分别进行单独评估，计算其评价得分 $J(x_i)$ ，然后按得分从大到小排序，选取前 d 个特征。

- 优点：算法极简，计算量极低。
- 缺点：完全忽略了特征之间的相关性，无法处理特征冗余。

3. 序贯搜索算法 (Sequential Search) 这是一种贪心算法，通过每一步的局部最优选择来逼近全局最优。

Algorithm 1 前向序贯选择算法 (SFS)

Require: 特征全集 $X = \{x_1, \dots, x_D\}$, 目标维度 d

Ensure: 最优特征子集 $X_{selected}$

- 1: 初始化 $X_{curr} \leftarrow \emptyset$
 - 2: **for** $k = 1$ **to** d **do**
 - 3: 寻找 $x_j \in X \setminus X_{curr}$, 使得 $J(X_{curr} + \{x_j\})$ 最大
 - 4: $X_{curr} \leftarrow X_{curr} \cup \{x_j\}$
 - 5: **end for**
 - 6: **特点:** 一旦特征被加入，后续步骤无法将其删除。
 - 7: **return** X_{curr}
-

4. 其它序贯变体

- **GSFS (广义 SFS):** 每次不是加入 1 个特征，而是加入 k 个特征，使得组合后性能最优。其计算量比标准 SFS 大。

- **SBS (后向序贯选择)**: 从全集开始, 每次剔除一个特征 $x_j \in X_{curr}$, 使得剩余特征集的评价准则 $J(X_{curr} - \{x_j\})$ 最大。其特点是“一旦删除, 无法增加”。
- **GSBS (广义 SBS)**: 每次从当前集合中剔除 k 个特征。

5. L-R 法 (Plus-L Minus-R) 为了克服 SFS 和 SBS “只进不出” 或 “只出不进” 的单向性缺陷, L-R 法采用交替增减的策略:

- **先 L 后 R**: 每次先通过 SFS 增加 L 个特征, 再通过 SBS 减少 R 个特征。
- **策略逻辑**: 若 $L > R$, 最终特征数增加; 若 $L < R$, 最终特征数减少。
- **公式表达**: 每次寻优后的集合为 $X_d = X_{d1} + \{x_j\}_L - \{x_i\}_R$ 。
- **广义 L-R (ZL, ZR)**: 更进一步, 增加 L 个和减少 R 个的过程分 Z 步进行, 通过复杂的步长控制来更深层地搜索特征组合空间。

1.1.3 算法特性对比

搜索算法	核心逻辑	主要局限
穷举法	遍历所有 $2^D - 1$ 种组合	计算复杂度爆炸
单独最优	按单特征 J 值排序	忽略特征间相关性
SFS	从 0 开始, 逐个增加最优特征	无法剔除已入选的过期特征
SBS	从 D 开始, 逐个剔除最差特征	无法找回已删除的潜在特征
L-R 法	增加 L 个再减少 R 个	需手动调参 L 和 R

1.2 特征评价准则：衡量特征子集的优劣

定义 1.2 (特征评价准则). 特征评价准则是一个函数 $J(X_{selected})$, 用于定量评估所选特征子集的分类贡献或表达能力。评价准则主要分为两类:

- **可分性度量**: 利用类别间的几何距离、分布重叠度或统计相关性进行打分, 常用于 Filter 框架。
- **学习算法精度度量**: 直接利用分类器的准确率 (Accuracy) 或错误率 (Error Rate) 作为得分, 常用于 Wrapper 框架。

1.2.1 基于距离的可分性判据

这类判据的核心思想是：好的特征子集应该使得“类内距离尽可能小，类间距离尽可能大”。这通常依赖于对样本散度矩阵的计算。

1. 基础数据统计量 假设特征选择后的样本向量为 x'_j ，第 i 类的平均向量为 m_i ，总平均向量为 m ，样本总数为 n 。

- **类内散度矩阵 (Within-class Scatter Matrix)**: 表示第 i 类样本内部的离散程度。

$$S_i = \frac{1}{n_i} \sum_{j=1}^{n_i} (x'_j - m_i)(x'_j - m_i)^T$$

- **总类内离散度矩阵 (S_w)**: 各类别散度矩阵的加权和。

$$S_w = \sum_{i=1}^c P_i S_i \quad (P_i \text{ 为第 } i \text{ 类的先验概率})$$

- **类间散度矩阵 (S_b)**: 表示各类别中心相对于总平均值的离散程度。

$$S_b = \sum_{i=1}^c (m_i - m)(m_i - m)^T$$

2. 常用可分性判据 J_f

- **一维特征 (两类)**: 采用比值形式。

$$J_f = \frac{(m_1 - m_2)^2}{S_1^2 + S_2^2}$$

- **多维特征子集**: 常用的矩阵判据包括:

- $J_1 = \text{tr}(S_w + S_b)$: 总散度。
- $J_2 = \text{tr}(S_w^{-1} S_b)$: 类间与类内散度的比率 (最常用)。
- $J_3 = \ln \frac{|S_b|}{|S_w|}$: 行列式比值的对数。
- $J_4 = \frac{\text{tr}(S_b)}{\text{tr}(S_w)}$: 迹的比值。
- $J_5 = \frac{|S_b - S_w|}{|S_w|}$: 差值的比例。

1.2.2 基于概率分布的可分性判据

从类别概率密度函数的角度出发，衡量两个类别在特征空间中的交叠程度。重叠越少，距离越远， J 值越大。

1. 基本性质 一个合理的概率距离准则 J 应满足：

1. $J \geq 0$ 。
2. 当类别完全不重叠 ($p(x|\omega_1)p(x|\omega_2) = 0$) 时, J 达到最大值 J_{max} 。
3. 当类别完全重合 ($p(x|\omega_1) = p(x|\omega_2)$) 时, $J = 0$ 。

2. 常见的概率距离准则

- **Bhattacharyya 距离**: 衡量概率分布的相似度。

$$J_B = -\ln \int [p(x|\omega_1)p(x|\omega_2)]^{1/2} dx$$

- **Chernoff 距离**: Bhattacharyya 的广义形式。

$$J_C = -\ln \int p^s(x|\omega_1)p^{1-s}(x|\omega_2)dx \quad (0 \leq s \leq 1)$$

- **散度 (Divergence)**: 衡量两个分布之间的不对称性差异。

$$J_D = \int [p(x|\omega_1) - p(x|\omega_2)] \ln \frac{p(x|\omega_1)}{p(x|\omega_2)} dx$$

- **Matusita 距离**:

$$J_M = \left[\int (\sqrt{p(x|\omega_1)} - \sqrt{p(x|\omega_2)})^2 dx \right]^{1/2}$$

1.2.3 基于熵的判据（信息论视角）

利用信息论中的互信息来衡量特征变量 X 与类别标签 Y 之间的统计相关性。

1. **互信息 (Mutual Information)** 衡量特征 X 对消除类别 Y 不确定性的贡献程度, 反映了两者依存关系的强弱。

$$I(X; Y) = \sum_{x \in S_x} \sum_{y \in S_y} p(x, y) \ln \frac{p(x, y)}{p(x)p(y)}$$

2. **条件互信息** 在已知特征 Z 的条件下, X 和 Y 的统计依存程度。

$$I(X; Y|Z) = \sum_{x \in S_x} \sum_{y \in S_y} \sum_{z \in S_z} p(x, y, z) \ln \frac{p(x, y|z)}{p(x|z)p(y|z)}$$